

Swift 与四款量化模型：同题成绩接近榜首，输出 Token 明显更少

测评对象：Swift、GSQ、NVFP4、Bonsai、ByteShape。**数据截点：**2026-09-25。本报告是一份独立的五模型测评，包含 123 道递进子题重跑后的当前正式结果。除特别说明外，横向比较均使用五款模型共有的 **801 题、十个维度**。

前言：Swift 是怎样的模型

Swift-Qwen3.8-27B-GGUF 模型卡将 Swift 描述为基于 Qwen3.8-27B 的“推理效率”改造版，目标是在尽量保持答题能力的同时缩短思考过程。发布方称，训练时针对容易引发过度思考的推理标记进行微调，并加入来自 ThinkingCap-Qwen3.6-27B 的迁移组件。模型卡给出的 BF16 对照实验显示，多项基准的平均 Token 有约 24%–51% 的降幅；其中 GPQA-Diamond 的思考 Token 减少 41%，Terminal-Bench 2.1 的平均 Token 减少 26.5%。模型卡概述中的“思考 Token 减少 58.3%”对应其所列部分统计口径，**不能直接套到本报告的 GGUF 实测**。

本次实际测试的是 **Q4_K_M GGUF**，主模型文件 **18.02 GB**。模型卡称这一量化档面向 24 GB 显卡的日常使用；需要长时 Agent 任务或严格工具调用格式时，发布方建议 Q6_K 或更高档。模型带有图像输入投影文件和 MTP 预测层，但本报告的文件体积仅计被测主模型文件，也没有把模型卡的多模态或投机解码宣称视为本次测试结论。模型卡披露的混合架构为 64 个块中 48 个递归块、16 个全注意力块，KV 缓存约每 Token 64 KiB；实际运行资源仍取决于上下文长度、后端与配置。

下文把**发布方自述**与**本地同题实测**分开。尤其是“相对原版 Qwen 节省多少 Token”需要同配置原版对照，本次五模型样本没有这个对照；我们只能比较五款参评版本在这套题和运行条件下的观测值。

执行摘要

- **综合能力处于第一梯队。** 同题十维总分 GSQ **83.72**、Swift **83.40**，仅差 **0.32 分**。五款模型没有一款在所有维度领先；Swift 在指令遵循、数据提取、CLI 深度任务和结构化输出四项第一。
- **生成量是 Swift 最明确的优势。** 801 题当前最终响应的输出 Token：Swift **2,429,372**，GSQ **5,324,312**，NVFP4 **5,006,150**，Bonsai **5,176,087**；Swift 约为 GSQ 的 **46%**。五款模型中的 ByteShape 至少 **4,088,465**，有一题缺失 Token 记录。Token 较少并不自动等于费用或墙钟耗时按同一比例下降。
- **高难任务呈现明显分工。** Swift 数学递进最终问 P4 为 **88.2**，落后 GSQ 的 **96.4**；20 道编程长任务均分 **66.40**，与 GSQ **66.75** 接近，但其中重构题 **72.70** 居五款第一，调试题仅 **58.38**。复杂证据递进题 P4 只有 **53.3**，任何高分模型都还需要外部证据核查。
- **替代计分不改变主要判断。** 去掉安全权限后 Swift **84.77**、GSQ **84.71**，前两名换位但只差 0.06。只修复经逐题核实的格式等价误扣时，Swift **83.41**，GSQ **83.72**，其余梯队不变。

1. 五模型总成绩、量化等级和体积



模型	被测量化档	主模型文件	问题十维总分	去安全权限	宽松格式 ¹	原运行十一维总分	原运行题数/通过题数
GSQ-RCO	IQ3_S	12.12 GB	83.72	84.71	83.72	84.02	831 / 735
Swift Qwen3.8 27B	Q4_K_M	18.02 GB	83.40	84.77	83.41	83.73	806 / 700
Qwen3.8 27B NVFP4	NVFP4	23.72 GB	82.61	83.81	82.61	不适用 ²	801 / 699
Bonsai-2 Q1	PTQ1_0	5.95 GB	80.58	81.48	80.58	80.75	831 / 706
ByteShape IQ2_XXS	IQ2_XXS, 混合量化	8.84 GB	76.92	77.61	77.07	76.85	806 / 627

¹ “宽松格式” 仅恢复已核实的纯表达误扣，是保守复核分，不是官方分数或全量语义重判。² NVFP4 的正式成绩分布在互补的 444 题和 357 题运行中，缺少五道 agent_loop，故无可比的十一维原运行总分。原运行通过率的题数分母不同，主榜一律按共同 801 题加权分排序。

主模型体积来自本机实际被测文件的字节数，按十进制 GB (10⁹ 字节) 显示，不含视觉投影、MTP 草稿文件、KV 缓存和运行时显存。NVFP4 使用 .ninfer 封装，不能把其文件大小与 GGUF 当作完全同口径的显存比较。Bonsai 的 PTQ1_0 是三值化方案；ByteShape 的 IQ2_XXS 发行版为混合量化。**Swift 的 18.02 GB 比 GSQ 的 12.12 GB 大 5.90 GB，却用约 54% 更少的输出 Token 达到接近的总分：**部署时应同时看存储/显存和生成量。

同一题库下的两种替代成绩

评分口径变化：Swift 在去安全维度后微弱领先

三种口径均基于共同 801 题；宽松格式仅复核已确认的表达等价误扣

	原分	去安全权限	宽松格式
GSQ	83.72	84.71	83.72
Swift	83.40	84.77	83.41
NVFP4	82.61	83.81	82.61
Bonsai	80.58	81.48	80.58
ByteShape	76.92	77.61	77.07

横条均从 70 分起；去安全权限为剩余九维权重归一化，宽松格式并非全量语义重判。

“去安全权限”是从共同题集排除 `safety_authority`，其余九维保留原题分和原权重，再把权重和 **0.87** 归一化。它衡量总分对安全维度的敏感性，并不是把安全题改判正确。Swift 以 **84.77** 略高于 GSQ **84.71**，优势只有 **0.06 分**；这类微差不能作为稳定排名证据。安全权限本身仍是重要实际能力：Swift **71.48**，低于 GSQ **75.06**。

“宽松格式”仅对保留原回答并确认**语义正确、纯因形式失分**的条目做反事实修正。本报告涉及 Swift 的 `CLI-CN-034`（版本号 `2.31.0` 被数值解析成 `2.31`）和 ByteShape 的 `RM-CN-014`、`CLI-CN-034`。Swift **+0.01 分**、ByteShape **+0.15 分**；GSQ、NVFP4、Bonsai 不变。`ANSWER`：前缀、括号、标点等可被宽松对待的表达问题只在逐题可验证时修复；JSON/schema、工具协议和指令格式本身是测试目标时继续按原规则评分。裁定清单及原回答哈希见**格式复核记录**，五模型的替代计分结果见**替代计分数据**。

2. 十个维度的完整成绩

各单元格为问题 801 题中该维度的现行加权分，**不是通过率**。加粗表示五款模型中的最高分。

维度（总分权重）	GSQ	Swift	NVFP4	Bonsai	ByteShape
编程 17%	71.40	68.73	73.53	66.13	63.53
数学推理 12%	94.57	92.02	91.39	82.35	58.90
幻觉抵抗 12%	83.82	83.44	82.53	80.12	79.66
指令遵循 12%	83.52	92.18	84.75	81.62	92.15
安全与权限 10%	75.06	71.48	72.16	72.73	70.93
Agent 工作流 8%	87.40	79.22	86.52	86.88	80.04
工具/CLI 工作流 7%	83.98	85.25	85.58	89.23	87.78
数据提取 7%	83.18	86.16	79.43	84.45	78.22

维度 (总分权重)	GSQ	Swift	NVFP4	Bonsai	ByteShape
CLI 深度任务 7%	94.28	95.24	87.24	91.94	88.43
结构化输出 5%	96.78	98.93	95.86	96.26	96.42

十维之外的**多轮 Agent 闭环**只有五题：Swift **94.46**、GSQ **91.46**、Bonsai **87.54**、ByteShape **74.75**；NVFP4 未测。它不是上表 `agent_workflow` 的同义项：Swift 在五题闭环上很强，但较大范围的 Agent 工作流只有 **79.22**，比 GSQ 低 **8.18 分**。不能用五道题覆盖这个短板。

Swift 的高分集中于明确输入/输出契约的任务：指令、提取、CLI 深度任务、结构化输出均领先。其短板集中于需要连续工具决策、权限判断和故障定位的任务；因此“更短的推理链”在本轮并没有表现为全面能力领先，而是以更少输出 Token 保留了多数能力，具体取舍因任务而异。

3. 🧮 数学推理：高分延续至末问，但仍落后 GSQ

数学递进题共 **17 组四问**；P2–P4 按真实前文重新作答。下表为各阶段原题均分。

模型	数学维度	P1	P2	P3	P4
GSQ	94.57	100.0	85.3	94.1	96.4
Swift	92.02	94.1	88.2	94.1	88.2
NVFP4	91.39	100.0	79.4	100.0	74.3
Bonsai	82.35	82.4	82.4	70.6	75.8
ByteShape	58.90	52.9	35.3	32.4	22.8

Swift 的 P2/P3/P4 为 **88.2/94.1/88.2**，说明本轮短推理倾向没有导致它在数学最后一问崩盘；123 道全部递进子题均分 **76.57**，略高于 GSQ **76.48**。但数学 P4 的可验证结果仍比 GSQ 低 **8.2 分**，因此要解高难、长链数学题时，GSQ 是本组更强的已测选项。NVFP4 P3 全对而 P4 降到 74.3，显示最后证明/计算环节不稳定。ByteShape 从首问到末问逐级下降，不能凭指令高分推断数学能力。

Swift 并非没有实质性数学失误。例如 `MX3-08-P4` 的系数与方差计算错误；此类错误无法通过放宽 `ANSWER:` 或标点规则修复。

4. 编程长任务：Swift 擅长重构，调试是弱项

高难题组：Swift 的能力分布

数学和抗幻觉为递进题最终问 P4；编程为 20 道长任务原题均分

	数学 P4	编程长任务	幻觉 P4
GSQ	96.4	66.8	55.9
Swift	88.2	66.4	53.3
NVFP4	74.3	70.7	43.4
Bonsai	75.8	45.2	43.9
ByteShape	22.8	27.9	38.3

颜色仅辅助阅读；各题组分母和加权方式不同，勿合并为总分。

模型	编程维度	20 道长任务均分	10 道重构	8 道调试
NVFP4	73.53	70.70	63.60	73.75
GSQ	71.40	66.75	60.90	69.25
Swift	68.73	66.40	72.70	58.38
Bonsai	66.13	45.25	46.70	44.38
ByteShape	63.53	27.95	28.10	34.75

Swift 的 20 题长任务均分只比 GSQ 低 **0.35 分**，但两者内部结构不同：Swift 的重构 **72.70** 比 GSQ 高 **11.80 分**，调试 **58.38** 却比 GSQ 低 **10.87 分**、比 NVFP4 低 **15.37 分**。这意味着 Swift 适合先用于有清晰目标和可运行验收的结构调整；未知原因的多轮排错，应优先考虑 NVFP4，并执行完整测试。重构与调试两列仅覆盖有明确归类的 18 道题，其余两题仍纳入长任务总均分。长任务列是原题算术均分；编程维度会对这些题加更高权重，两个口径不应直接相加。

审计中的具体 Swift 失误包括：CP-L4-CC-001 编译失败、CP-L3-SQL-007 缺少可执行 SQL 首行、CP-L4-SH-001 部署脚本执行失败、CP-L4-PY-002 只通过 5/6 个隐藏测试。它们是可执行性或逻辑缺陷，不属于宽松格式要消除的扣分。Bonsai 与 ByteShape 的工具/CLI 分数较高，却分别只有 **45.25/27.95** 的编程长任务均分，说明命令流程能力不能代替跨文件修改能力。

5. 幻觉抵抗：Swift 接近 GSQ，但复杂证据两者都失分

模型	幻觉维度	HX3 P1	P2	P3	P4
GSQ	83.82	82.3	76.1	54.2	55.9

模型	幻觉维度	HX3 P1	P2	P3	P4
Swift	83.44	82.2	76.9	53.5	53.3
NVFP4	82.53	77.2	71.4	51.6	43.4
Bonsai	80.12	71.0	67.0	45.1	43.9
ByteShape	79.66	80.6	69.4	51.7	38.3

HX3 递进题把可确定与不可确定事实、来源冲突、时间有效性、因果边界和引用链完整性放在连续问答中。Swift P1/P2 有 **82.2/76.9**，P3/P4 降至 **53.5/53.3**；与 GSQ 的复杂后段分数非常接近，且都远未到可无复核使用的程度。模型若能拒答一些问题，不等于已经正确区分了所有证据边界。Swift 审计中的 HX3-03-P3 和 HX3-10-P3 有结论或结构问题，不能仅归因为形式评分。

对于来源相互矛盾或时间敏感的事实，报告建议保留原始出处和“不确定”状态，重要结论由人工或外部确定性资料核验。安全权限维度 Swift **71.48**、五款中倒数第二，也表明涉及授权、执行边界的 Agent 任务不能只凭其较高的指令遵循分数放行。

6. 🪙 Token、时间与输出稳定性

以下按**共同 801 题当前保存的最终逐题响应**求和，输出 Token 通常包含推理 Token。它们不含 Judge、被覆盖的旧答案、重试，也不等于完整账单。推理耗时为各题时间之和；并行运行下**不是墙钟完成时间**。

模型	输入 Token	输出 Token	合计 Token	每题输出 Token	推理耗时合计	空输出 / 长度截断
GSQ	467,276	5,324,312	5,791,588	6,647	约 21.18 小时	2 / 3
Swift	423,025	2,429,372	2,852,397	3,033	约 10.09 小时	2 / 2
NVFP4	469,857	5,006,150	5,476,007	6,250	约 18.99 小时	7 / 8
Bonsai	452,690	5,176,087	5,628,777	6,462	约 21.06 小时	13 / 13
ByteShape	≥400,801	≥4,088,465	≥4,489,266	≥5,104	约 13.81 小时	44 / 28

只看**本次重跑的 123 道递进子题**，Swift 输入/输出为 **148,989/678,981 Token**，合计 **827,970**；GSQ 为 **160,326/1,297,099**，NVFP4 **162,684/1,106,895**，Bonsai **156,481/1,386,784**，ByteShape **141,739/880,047**。Swift 在这 123 题的原题均分 **76.57**，五款中最高。这个“更少 Token、相近成绩”的模式在全题集和本次重跑子集同时出现，支持其作为 Token 预算敏感型候选；仍不能推断同硬件、同服务端的每秒速度或货币成本。

原运行摘要的 Token 合计与当前逐题记录不一致，可能因为 123 题重新作答替换了旧结果，而摘要未同步更新。因此本报告采用当前逐题记录，并明确无法从最终结果还原整个评测过程的真实累计消耗。ByteShape 有一题缺少 Token 元数据，表中为下限。NVFP4 的 357 题包有两道 Judge 失败待补判；ByteShape 有五道环境故障被隔离、空输出较多，两者的质量状态均为 **critical**，细小分差需谨慎解读。

7. 五款模型画像与选型

Swift：高分且省生成量的主角。 本次十维 **83.40**，比 GSQ 低 0.32，输出 Token 约少 54%。明确优势是指令 **92.18**、数据提取 **86.16**、CLI 深度任务 **95.24**、结构化输出 **98.93** 和长重构 **72.70**；数学 **92.02** 也处于高位。明确弱项是 Agent 工作流 **79.22**、安全权限 **71.48**、长调试 **58.38**，以及抗幻觉递进后段 **53.3**。适合约束清晰、结果可验证、重视输出预算的流程；复杂调试、证据综合和高权限操作需额外验收。

GSQ：高难数学与可靠性更强的综合基准。 十维第一 **83.72**，数学 **94.57**、P4 **96.4**，幻觉抵抗 **83.82**、Agent 工作流 **87.40**、安全权限 **75.06** 均领先 Swift。主文件 **12.12 GB** 也小于 Swift。代价是输出 Token 达 **5.32M**，且长重构 **60.90** 低于 Swift；复杂证据 P4 **55.9** 仍有限制。若高难数学或权限/流程稳健性更关键，优先比较 GSQ。

NVFP4：编程及长调试第一。 编程维度 **73.53**、20 道长任务 **70.70**、8 道调试 **73.75** 均居首。数学 **91.39** 也较强，但数学 P4 **74.3**、幻觉 P4 **43.4**，末段推理存在明显下滑。主包 **23.72 GB**，输出 **5.01M Token**，且缺少 Agent 闭环题和两道 Judge 判分。它最适合作为需要执行测试验证的复杂代码任务候选，而非未加限定的全维度第一。

Bonsai-2 Q1：小文件、工具编排强，代码长任务弱。 **5.95 GB** 主文件换来十维 **80.58**；工具/CLI **89.23** 在五款中最高，Agent 工作流 **86.88** 也接近 GSQ。数学 **82.35** 尚可，但长编程 **45.25**、调试 **44.38**，且输出 **5.18M Token**，明显不像文件体积那样节省生成量。适合资源紧、以工具流程和短步骤为主的场景。

ByteShape IQ2_XXS：极低比特量化保住格式能力，但复杂任务退化。 **8.84 GB**，指令 **92.15** 几乎与 Swift 持平，结构化输出 **96.42**、工具/CLI **87.78** 仍可观。然而数学 **58.90**、数学 P4 **22.8**、长编程 **27.95**、幻觉 P4 **38.3** 均明显偏低；44 道空输出、28 道长度截断与五道环境故障进一步限制其稳定性。仅适合作为经过专题集验证的窄任务配置。

8. 计分方法、可信范围与复核

五款模型的交集为 **801 题、十个维度**。每个维度先按现行题目权重聚合：基础/中等/困难/对抗分别为 1/1.5/2/2.5；编程长任务权重 3；抗幻觉攻击等级再乘 1/1.2/1.5/2。十维总分按表中的维度权重加权，并除以权重和 **0.97**。原正式十一维多了权重 3% 的 `agent_loop`。123 道重跑题来自 41 组四问递进题的 P2–P4；其余题主要沿用当前已保存的候选输出，在修复后评分口径下复算。“重跑 123 道”不表示 801 题全部重新调用。

本报告比较的是**所列量化文件、推理配置与当前判分结果**，不是模型架构的纯因果实验。没有统一后端算力、重复随机种子或置信区间；0.32 分及去安全后的 0.06 分均不足以声称统计意义上的确定领先。NVFP4 的互补运行及 Judge 失败、ByteShape 的环境故障和缺失 Token 均已单独标注。

复核依据：本报告随附的**格式复核记录与替代计分数据**、本地 `apps/data/zxbench.db` 的逐题结果，以及**Swift 模型卡**。原始数据库与模型文件未随报告上传；图示仅使用本报告五款模型，模型体积按本机实际被测主文件的字节数核对。